


Herramientas para la Ciencia de datos

Data Science

Categorías de las herramientas para DS

OBJETIVOS

Identificar las tareas que un Data Scientist requiere realizar.



Mostrar como la gestión de activos de código y la gestión de activos de datos ayudan a crear modelos




Describir como los entornos de ejecución y desarrollo implementan un modelo.




Categorías de las herramientas para DS

Los datos sin procesar deben pasar por diversas tareas de DS, como la integración y transformación de los datos, visualización, construcción e implementación del modelo, administración de los activos de los datos, entornos de desarrollo y entornos de ejecución.




Herramientas de código abierto para DS



Categorías de las herramientas para DS

DATA MANAGEMENT:


- Se encarga de recopilar, conservar y recuperar datos de forma segura, eficiente y rentable.
- Los datos se pueden recopilar de muchas fuentes como:




Herramientas de código abierto para DS

DATA MANAGEMENT:

- Las herramientas de administración de datos de código abierto más utilizadas son las bases de datos relacionales como MySQL y PostgreSQL.
- Además hay bases de datos como MONGO, APACHE, CouchDB y Apache Cassandra.
- Existen herramientas basadas en archivos como el sistema de archivos Hadoop o sistemas de archivos en la nube como Ceph.
- Herramientas de búsqueda de datos que almacena datos de texto.




Herramientas de código abierto para DS



Categorías de las herramientas para DS

DATA INTEGRATION AND TRANSFORMATION:



- Proceso de extracción, transformación y carga de datos (ETL).
- Extraer los datos y almacenarlos en un repositorio central, como un almacén de datos.



Categorías de las herramientas para DS

DATA INTEGRATION AND TRANSFORMATION:

- La transformación de datos, es el proceso de transformar, los valores, la estructura y el formato de los datos. Una vez transformados los datos se vuelven a cargar a almacén de datos




Herramientas de código abierto para DS

DATA INTEGRATION AND TRANSFORMATION:

- Extraer, transformar y cargar (ETL).
- Otro término es: refinera y limpieza de datos.
- Herramientas open source mas utilizadas: Apache AirFlow, KubeFlow, Apache Kafka, Apache Nifi, Apache SparkSQL, NodeRed





Herramientas de código abierto para DS



Categorías de las herramientas para DS

DATA VISUALIZATION:

- Representación gráfica de los datos y la información. Puede utilizar diversos formatos como gráficas, mapas, animaciones, etc.
- La visualización de los datos transmite los datos de forma más eficaz a los responsables de la toma de decisiones.




Herramientas de código abierto para DS

DATA VISUALIZATION:

- Debe distinguir entre las bibliotecas de programación en las que deben usar código o herramientas que contengan una interfaz de usuario.
- PixieDust, librería con interfaz de usuario (python).
- Hue, crea visualizaciones a partir de queries de SQL.
- Kibana, aplicación web de exploración y visualización de datos, se limita a Elasticsearch.
- Apache Superset aplicación web de exploración y visualización de datos.




Herramientas de código abierto para DS




Categorías de las herramientas para DS

MODEL BUILDING:

- La creación del modelo es el paso donde entrenas los datos y se analizan los patrones con algoritmos de aprendizaje automático (Machine Learning, ML)
- El sistema aprende a proporcionar decisiones o predicciones por si mismo. Posteriormente el modelo puede ser utilizado para hacer predicciones sobre datos nuevos e invisibles.



Herramientas de código abierto para DS




Herramientas de código abierto para DS

Model Deployment:

- Apache PredictionIO solo compatible con modelos de Apache Spark ML para su implementación.
- Seldon compatible con casi todos los entornos como TensorFlow, Apache SparkML, R, scikit Learn.
- TensorFlow puede servir con cualquier modelo mediante el servicio de Tensor Flow, TensorFlow Lite



Herramientas de código abierto para DS



Categorías de las herramientas para DS

MODEL MONITORING AND ASSESSMENT:

- La supervisión y evaluación de los modelos realizan controles de calidad continuos para garantizar la precisión , la imparcialidad y solidez del modelo.
- La supervisión de modelos utiliza herramientas como Fiddler para realizar un seguimiento del rendimiento.








La evaluación del modelo utiliza métricas como: F1-Score, Accuracy, RMSE, MAE y otras.




Herramientas de código abierto para DS

Model Monitoring and assessment:

- Seguimiento de su rendimiento de predicción.
- ModelDB es una base de metadatos de modelos que se almacena y consulta información sobre los modelos. Es compatible con Apache Spark ML pipelines y Scikit-learn.
- Prometheus no es tan común pero permite medir al modelo más que por su precisión.



Herramientas de código abierto para DS



Categorías de las herramientas para DS

CODE ASSESSMENT MANAGEMENT:

- La gestión de activos de código proporciona una vista unificada en la que se gestiona un inventario de activos.
- Para realizar la actualización, mantenimiento del modelo, es necesario realizar cambios, corregir errores; lo que requiere llevar un control de versiones.
- Los desarrolladores utilizan el control de versiones para realizar un seguimiento y gestionar los cambios del código de un proyecto de sw.
- La colaboración permite que distintas personas compartan y actualicen el mismo proyecto de forma conjunta.




Herramientas de código abierto para DS

Code Assets Management:

- Gestión de versiones como Github, GitLab (plataforma de código abierto), Bitbucket.



Herramientas de código abierto para DS



Categorías de las herramientas para DS

DATA ASSESSMENT MANAGEMENT:

- La gestión de activos de datos, también denominada Gestión de Activos Digitales (DAM) consiste en organizar y gestionar datos importantes recopilados de diferentes fuentes.
- Es una plataforma que permite el control de versiones y la colaboración.
- También admiten la realización, el respaldo y la administración de los derechos de acceso de los datos almacenados.

Herramientas de código abierto para DS

Data Assets Management:

- Conocida como gobierno de datos, donde los datos deben estar versionados y anotados con metadatos.
- Apache Atlas, ODPI EGERIA (gestionado por la fundación de Linux y ofrece conjunto de APIs




Apache Atlas



kylo™

Herramientas de código abierto para DS



Categorías de las herramientas para DS

Developed Environments:


- También llamados entornos de desarrollo integrados (IDEs) proporcionan un espacio de trabajo y herramientas para desarrollar, implementar, ejecutar, probar e implementar el código fuente.




Herramientas como Watson Studio proveen herramientas de pruebas y simulación permiten emular el mundo real y ver como se comporta el modelo.

Categorías de las herramientas para DS

Developed Environments:



Herramientas de código abierto para DS



Categorías de las herramientas para DS

Execution Environments:

- Un entorno de ejecución tiene bibliotecas para compilar el código fuente y los recursos del sistema que ejecutan y verifican el código.
- Los entornos de ejecución basados en la nube no están vinculados a ningún software o hardware específico y ofrecen herramientas para el preprocesamiento de datos, entrenamiento de modelos y el despliegue.

Categorías de las herramientas para DS

Execution Environments:



Enables large scale deep learning
model training

